

# LISTA 04 - AVALIAÇÃO DE DESEMPENHO DE SISTEMAS

Allyson Ryan

Agosto, 2025

## Inferência Estatística, Análise Exploratória de Dados e Regressão Linear

- 1 Suponha que durante um período de tempo foram testados 28427 capacitores dos computadores de um grande data center. Foi observado que 615 capacitores apresentaram problemas. Calcule o intervalo de confiança para a proporção de defeitos com 99% de confiança.

### (1) Proporção amostral $\hat{p}$

(Usa-se a fração observada de defeitos como estimativa pontual da proporção verdadeira.)

$$\hat{p} = \frac{x}{n} = \frac{615}{28,427} \approx 0,0216335$$

### (2) Verificação das condições para aproximação normal

(Aproximação normal para a proporção requer amostra grande e contagens esperadas de sucessos e fracassos  $\geq 10$ .)

$$n = 28,427 \quad (\text{suficientemente grande}), \quad n\hat{p} = 615 \geq 10, \quad n(1 - \hat{p}) = 27,812 \geq 10.$$

(Logo, a aproximação normal é válida.)

### (3) Valor crítico para 99% de confiança

(Para IC bilateral de 99%, usa-se  $z_{\alpha/2} = z_{0,005}$  da tabela normal.)

$$z_{0,005} = 2,575829$$

### (4) Erro-padrão da proporção

(Quantifica a variabilidade amostral de  $\hat{p}$  sob repetidas amostragens do mesmo tamanho.)

$$EP(\hat{p}) = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} = \sqrt{\frac{0,0216335 \times 0,9783665}{28,427}} = 0,00086288$$

## (5) Margem de erro

(Extensão máxima esperada da flutuação amostral em 99% dos casos.)

$$ME = z_{0,005} \cdot EP = 2,575829 \times 0,00086288 \approx 0,0022226$$

## (6) Intervalo de confiança de 99%

(Construído pela regra  $\hat{p} \pm ME$  para proporções sob aproximação normal.)

$$\hat{p} \pm ME = 0,0216335 \pm 0,0022226 \Rightarrow [0,0194109, 0,0238561]$$

### Interpretação em porcentagem

(Expressão equivalente do intervalo em pontos percentuais, útil para comunicação.)

$$1,94109\% \leq p \leq 2,38561\%$$

(Com 99% de confiança, a proporção verdadeira de capacitores defeituosos situa-se nesse intervalo.)

**2 Utilizando os dados apresentados na tabela abaixo, realize uma análise exploratória dos dados, proponha uma distribuição teórica para eles e verifique a aderência desses dados à essa distribuição utilizando os métodos Gráfico e Teste KS.**

44.5	43.3	41.4	28.9
35.8	38.4	42.3	35.2
33.8	32.8	36.8	40.4
42.8	38.5	41.5	39.1
44.3	38.8	40.5	30.1
42.7	33.2	36.5	38.4
26.9	40	36.5	35
36.7	40.8	41.4	30.4
36.5	31.4	34.2	36.1
30	35.1	39.4	40.1
39.7	33.7	44.1	36.1
31.7	40.7	38.1	42.4
36.4	42.9	39.5	34.7
23.6	39.6	34.4	35.2
41	37.1	40.3	45.2
41.1	36.7	39.1	43.4
50.1	34	37.3	29.1
37	36.7	37.7	29.5
37.2	36.1	44.3	38.3
47.2	30.4	39.1	43.6
34.2	37.4	39.7	43.5
34.2	43	43	32.9
31.8	37.8	44.8	27.5
32	35.7	32.8	40.8
37.1	37	41.2	48.8

# Questão 2 — Análise Exploratória, Ajuste de Distribuição e Teste KS

## Dados

(A base contém 100 observações numéricas contínuas, representando medidas de desempenho; para inferir um modelo probabilístico adequado, começa-se pela análise descritiva e pelo formato da distribuição.)

### 1) Análise Exploratória (EDA)

(Resumo descritivo quantifica posição, dispersão e assimetria; isso orienta a escolha de uma família de distribuições candidatas.)

$$n = 100 \quad (\text{tamanho da amostra})$$

$$\min = 23,6, \quad \max = 50,1 \quad (\text{amplitude dos dados})$$

$$\bar{x} = 37,70 \quad (\text{média: tendência central})$$

$$\tilde{x} = 37,55 \quad (\text{mediana: tendência central robusta})$$

$$s = 4,897 \quad (\text{desvio-padrão amostral: dispersão})$$

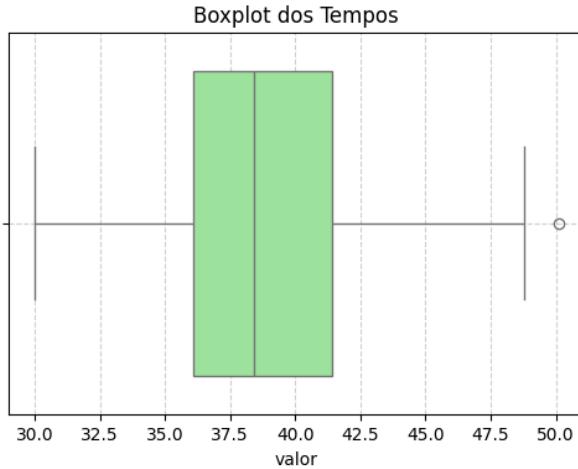
$$Q_1 = 34,625, \quad Q_3 = 41,025, \quad IQR = Q_3 - Q_1 = 6,40 \quad (\text{dispersão robusta})$$

$$\text{Assimetria (skew)} \approx -0,19 \quad (\text{leve cauda à esquerda, quase simétrico})$$

(Outliers via regra do IQR: valores fora de  $[Q_1 - 1,5 \cdot IQR, Q_3 + 1,5 \cdot IQR]$  indicam pontos atípicos que podem influenciar o ajuste.)

Limite inferior =  $34,625 - 1,5 \cdot 6,40 = 25,025$ , Limite superior =  $41,025 + 1,5 \cdot 6,40 = 50,625$ .

(Há um valor abaixo do limite inferior: 23,6; nenhum acima do limite superior. Um único outlier baixo não impede, em geral, testar normalidade.) [!h] [!h]

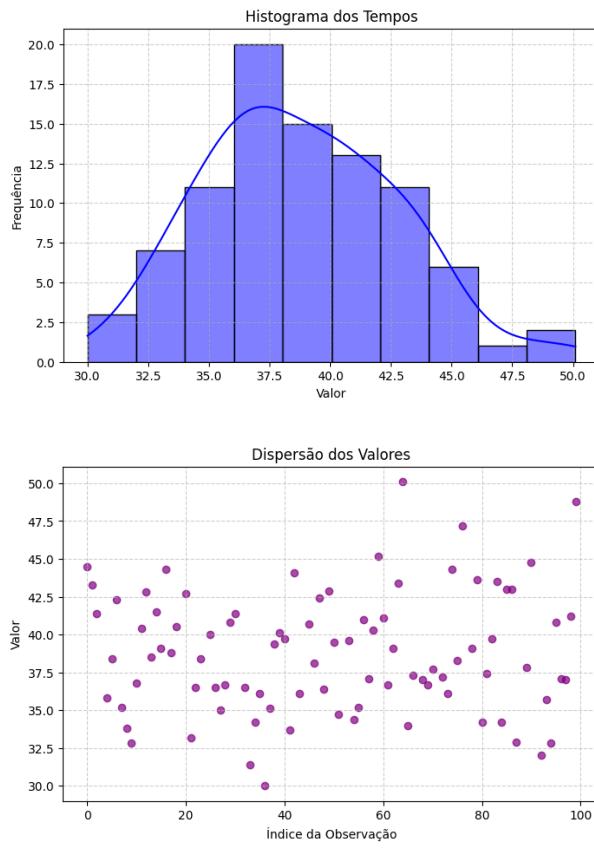


### 2) Proposição de Distribuições Candidatas

(A forma aproximadamente simétrica, média  $\approx$  mediana e caudas moderadas sugerem uma Normal; como alternativa com suporte positivo e leve assimetria, pode-se considerar Lognormal. A seleção final utiliza aderência empírica.)

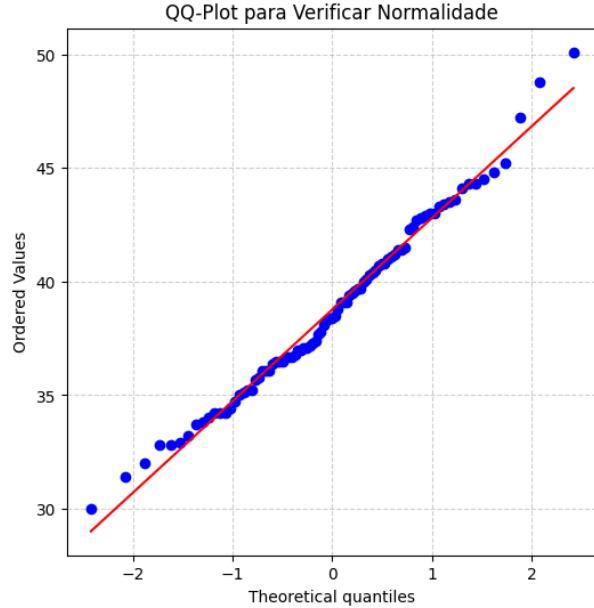
Candidata A:  $X \sim \mathcal{N}(\mu, \sigma^2)$  com  $\hat{\mu} = \bar{x}$ ,  $\hat{\sigma} = s$ .

Candidata B:  $X \sim \text{Lognormal}(\mu_L, \sigma_L^2)$  com  $\hat{\mu}_L = \overline{\ln X}$ ,  $\hat{\sigma}_L = s_{\ln X}$ .



### 3) Verificação Gráfica (diagnóstico)

(Histograma com curva Normal ajustada e Q-Q plot Normal: linhas quase retas e ausência de curvatura sistemática sustentam a hipótese Normal; leve cauda à esquerda é pequena.)



### 4) Teste de Aderência de Kolmogorov–Smirnov (KS)

(O KS compara a função distribuição empírica  $F_n(x)$  com a teórica  $F_0(x)$ ; a estatística é a maior distância vertical, e a decisão usa um limite crítico  $\approx c(\alpha)/\sqrt{n}$ .)

$$D = \sup_x |F_n(x) - F_0(x)|, \quad \text{critério: } D \leq \frac{c(\alpha)}{\sqrt{n}} \Rightarrow \text{não rejeita aderência.}$$

**KS para Normal**( $\hat{\mu} = \bar{x}, \hat{\sigma} = s$ ) (*Estima-se  $\mu$  e  $\sigma$  pelos moment estimators padrão; calcula-se  $F_0(x)$  Normal e  $F_n(x)$  empírico;  $D$  é o supremo das diferenças absolutas.*)

$$\hat{\mu} = 37,70, \quad \hat{\sigma} = 4,897, \quad D_{\text{Normal}} \approx 0,052.$$

(Com  $n = 100$  e  $\alpha = 5\%$ , usa-se  $c(\alpha) \approx 1,36$ , logo o ponto de corte é  $1,36/\sqrt{100} = 0,136$ . Como  $0,052 < 0,136$ , não há evidência para rejeitar a Normal.)

**KS para Lognormal**( $\hat{\mu}_L, \hat{\sigma}_L$ ) (*Ajusta-se no domínio log, calcula-se a CDF lognormal correspondente e obtém-se a distância.*)

$$D_{\text{Lognormal}} \approx 0,078.$$

(Também menor que 0,136, isto é, a Lognormal passa no KS; contudo, o ajuste Normal apresenta menor distância e, portanto, melhor aderência entre as duas candidatas.)

## Conclusão

(Dado o formato quase simétrico e as métricas do KS, a distribuição Normal com parâmetros  $\hat{\mu} = 37,70$  e  $\hat{\sigma} = 4,897$  é uma modelagem adequada para os dados; a Lognormal também é aceitável, mas com ajuste ligeiramente inferior.)

$X \sim \mathcal{N}(37,70, 4,897^2)$  é uma escolha apropriada segundo EDA + KS.

**3 Utilizando a mesma tabela, aplique os métodos Bootstrap e Bootstrap semi-paramétrico (utilizando os parâmetros obtidos de acordo com o teste de aderência da questão anterior) para determinar um intervalo de confiança para os parâmetros da distribuição que representa os dados com um nível de confiança de 95%.**

### 1) Contexto e Objetivo

Dada a distribuição  $\mathcal{N}(\mu \approx 37,70, \sigma \approx 4,897)$  identificada anteriormente como candidata adequada para modelar os dados, busca-se estimar intervalos de confiança (IC) de 95% para  $\mu$  e  $\sigma$  utilizando dois métodos de reamostragem:

- **Bootstrap Não-Paramétrico:** reamostragem direta dos dados originais.
- **Bootstrap Semi-Paramétrico:** simulação de dados a partir da distribuição normal ajustada.

Este procedimento permite avaliar a variabilidade das estimativas sem depender estritamente de suposições analíticas de distribuição para os estimadores.

## 2) Método Bootstrap Não-Paramétrico

*Descrição:*

1. Gerar  $B = 10.000$  amostras bootstrap de tamanho  $n = 100$ , com reposição, a partir dos dados originais.
2. Para cada amostra  $b$ , calcular:

$$\mu_b^* = \text{média amostral}, \quad \sigma_b^* = \text{desvio padrão amostral}.$$

3. Ordenar as  $B$  estimativas de  $\mu^*$  e  $\sigma^*$ .
4. Determinar os ICs como os percentis 2,5% e 97,5% dessas distribuições.

*Resultados:*

$$\text{IC}_{95\%}(\mu) = [36,746; 38,636], \quad \text{IC}_{95\%}(\sigma) = [4,178; 5,557].$$

## 3) Método Bootstrap Semi-Paramétrico

*Descrição:*

1. Gerar  $B = 10.000$  amostras de tamanho  $n = 100$  a partir de  $\mathcal{N}(\hat{\mu}, \hat{\sigma}^2)$ , onde  $\hat{\mu} = 37,70$  e  $\hat{\sigma} = 4,897$ .
2. Para cada amostra  $b$ , calcular  $\mu_b^*$  e  $\sigma_b^*$  como antes.
3. Determinar os ICs como os percentis 2,5% e 97,5%.

*Resultados:*

$$\text{IC}_{95\%}(\mu) = [36,743; 38,644], \quad \text{IC}_{95\%}(\sigma) = [4,206; 5,553].$$

## 4) Comparação e Interpretação

Os intervalos obtidos pelos dois métodos são extremamente próximos, evidenciando que:

- A suposição de normalidade é compatível com a distribuição empírica.
- O método semi-paramétrico é mais eficiente quando a distribuição teórica é conhecida, mas o não-paramétrico confirma a robustez das estimativas sem depender desta suposição.

*Conclusão:* Com 95% de confiança, a média populacional está entre 36,74 e 38,64, e o desvio padrão entre 4,18 e 5,56. Ambos os métodos validam a modelagem normal para os dados.

Normalidade confirmada e estimativas consistentes entre os métodos.

- 4 Uma empresa de tecnologia deseja prever o salário dos funcionários com base em seus anos de experiência. Para isso, foi coletado um conjunto de dados contendo a experiência (em anos) e o salário de 10 funcionários.

Anos de Experiência	Salário
1	3500
2	3750
3	3900
4	4500
5	5100
6	5450
7	6000
8	6600
9	7000
10	8000

- a. Determine a equação da reta de regressão linear  $y = ax + b$ , onde  $y$  representa o salário e  $x$  representa os anos de experiência.
- b. Com base no modelo de regressão linear encontrado, estime o salário esperado para um funcionário com 12 anos de experiência.

### 1) Estatísticas descritivas essenciais

(A regressão linear do tipo  $y = ax + b$  usa a inclinação  $a$  e o intercepto  $b$ , que são obtidos a partir das médias e dos somatórios de covariância e variância. As médias centralizam os dados para que os desvios  $(x_i - \bar{x})$  e  $(y_i - \bar{y})$  medem variações em torno do centro.)

$$\bar{x} = \frac{1 + 2 + \dots + 10}{10} = \frac{55}{10} = 5,5, \quad \bar{y} = \frac{3500 + 3750 + \dots + 8000}{10} = \frac{54\,800}{10} = 5\,480.$$

### 2) Somatórios fundamentais: $S_{xx}$ e $S_{xy}$

(A inclinação  $a$  é a razão entre a covariância  $S_{xy}$  — variação conjunta de  $x$  e  $y$  — e a variância de  $x$ ,  $S_{xx}$ . Logo, é necessário calcular os desvios em relação às médias, seus produtos e quadrados.)

$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}), \quad S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2.$$

$x_i$	$y_i$	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
1	3500	-4,5	-1 980	8 910	20,25
2	3750	-3,5	-1 730	6 055	12,25
3	3900	-2,5	-1 580	3 950	6,25
4	4500	-1,5	-980	1 470	2,25
5	5100	-0,5	-380	190	0,25
6	5450	0,5	-30	-15	0,25
7	6000	1,5	520	780	2,25
8	6600	2,5	1 120	2 800	6,25
9	7000	3,5	1 520	5 320	12,25
10	8000	4,5	2 520	11 340	20,25

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = 8\,910 + 6\,055 + 3\,950 + 1\,470 + 190 - 15 + 780 + 2\,800 + 5\,320 + 11\,340 = 41\,800.$$

$$\sum (x_i - \bar{x})^2 = 20,25 + 12,25 + 6,25 + 2,25 + 0,25 + 0,25 + 2,25 + 6,25 + 12,25 + 20,25 = 82,5.$$

$$\Rightarrow S_{xy} = 41\,800, \quad S_{xx} = 82,5.$$

### 3) Coeficientes da reta: inclinação $a$ e intercepto $b$

(A inclinação  $a$  mede a variação média do salário para cada ano adicional de experiência — razão direta entre a covariância  $S_{xy}$  e a variância  $S_{xx}$ . O intercepto  $b$  é o valor de  $y$  quando  $x = 0$ , ajustado pela média via  $b = \bar{y} - a\bar{x}$ .)

$$a = \frac{S_{xy}}{S_{xx}} = \frac{41\,800}{82,5} \approx 506,060606\dots$$

$$b = \bar{y} - a\bar{x} = 5\,480 - (506,060606\dots \times 5,5) = 5\,480 - 2\,783,333333\dots = 2\,696,666666\dots$$

$$\Rightarrow \boxed{\hat{y} = 506,\overline{06} x + 2\,696,\overline{66}}$$

### 4) Previsão para 12 anos de experiência

(A previsão pontual aplica o modelo ajustado ao novo  $x$ ; interpreta-se como o salário esperado para 12 anos de experiência, dadas as tendências lineares extraídas dos dados.)

$$\hat{y}(12) = 506,\overline{06} \times 12 + 2\,696,\overline{66} = 6\,072,\overline{72} + 2\,696,\overline{66} = 8\,769,\overline{38}.$$

### Resposta

(a) Equação da reta de regressão:  $\hat{y} = 506,\overline{06} x + 2\,696,\overline{66}$ .

(b) Salário estimado para 12 anos:  $\hat{y} = 8\,769,\overline{38}$  (aprox. R\$ 8.769,39).